深度学习模型压缩技术综述

一、研究背景

随着神经网络参数规模从百万级增长到千亿级，模型部署面临存储开销与*推理延迟*的双重挑战。已有研究表明，量化可以在几乎不损失精度的前提下将模型体积压缩至原来的 1/4。

模型压缩的主要技术路线包括：

- 剪枝（Pruning）：移除冗余连接或通道
- 量化（Quantization）：用低位宽表示权重
- 知识蒸馏（Knowledge Distillation）：用大模型指导小模型

1.1 量化误差分析

设权重为 W，量化后的权重为 $\hat{W}$，则量化误差可表示为：

$$\min_{W} \| W - \hat{W} \|_2^2$$

其中缩放因子 s 与零点 z 的取值直接决定了误差上界。

二、实验结果对比

方法	参数量**(M)**	准确率**(%)**	压缩率
Baseline	11.2	76.8	1.0x
8-bit 量化	11.2	76.5	3.9x
剪枝 + 量化	4.8	75.9	8.2x

从表中可见，剪枝与量化联合使用的收益最为显著。

三、实现细节

核心的伪量化函数如下：

```
def fake_quant(x, bits=8):
    scale = (x.max() - x.min()) / (2 ** bits - 1)
    zero_point = -x.min() / scale
    return (x / scale + zero_point).round() * scale
```

实验基于 PyTorch 1.13 完成，所有模型均在单卡 A100 上训练。

需要注意：上述指标是在 ImageNet 验证集上得到的，迁移到其他数据集时结论可能发生变化。

四、结论

本文系统比较了三类模型压缩方法，验证了联合策略的有效性。后续工作将进一步探索在移动端的实际部署效果。